

## tokenizer1 שאומן על domain 1:

הסבר על הטוקניזר ובמה הוא שונה מהאלגוריתם הבסיסי:

### 1. נרמול של הטקסט

- נרמול של lower case בשני מישורים: תיקון של מילים שיש בהן שילוב לא תקין של אותיות קטנות וגדולות למשל "Hello" → "HeLLo" והמרה לאותיות קטנות במקרים של כותרת במילות stop words – למשל "The" → "the".
- הסרה של סימני פיסוק עוקבים ואיחוד שלהם לתו אחד, למשל "!" → "!!!!".
- הסרה של רווחים מיותרים, למשל רווח כפול הופך לתו רווח אחד.
- הסרה של חזרתיות מיותרת של אותיות למשל "no" → "nooooo".

### 2. מימוש של pre-tokenization

- כל מילה סומנה עם תחילית מיוחדת <W> המסמלת תו רווח כדי לשמור על גבולות המילה.
- פיצול של תתי מילים עם התייחסות לפיסוק, למשל "hello-world!" יפוצל ל: "!", "world", "-", "hello".

### 3. זיהוי ואיחוד של bi-grams נפוצים והכנסה שלהם למילון

- הטוקניזר מזהה וממזג bi-grams לטוקן אחד, כאשר bi-grams מוגדרים להיות שתי מילים עם רווח ביניהן (למשל New York) ובנוסף לכך הטוקניזר מאחד שתי מילים שמופרדות ב"-" כך שנוכל לתפוס את ה-bigram "Rolls-Royce" לדוגמה.
- Bi-grams הכוללים מילות יחס (Determiners) או תוים שהם לא ASCII מסוננים מראש ולא נכללים באיחוד. אנחנו ממזגים רק צמדים שהופיעו בתדירות גבוהה מסף שהגדרנו (למשל  $\text{freq} > 10$ ).

### 4. האצה של תהליך ה encode

- במהלך שלב ה encoding, הטוקניזר עושה שימוש בזיכרון cache בשם merge\_ranks, המכיל את סדרי העדיפויות של כללי המיזוג שנלמדו באימון. לכל צמד תווים שהוגדר ככלל מיזוג, מוקצה דירוג (rank) המייצג את עדיפותו היחסית. בעת ה encode, הטוקניזר סורק את רצף התווים ובוחר בכל פעם את הצמד עם הדירוג הגבוה ביותר (כלומר, עם rank נמוך), תוך שימוש ב- merge\_ranks לצורך גישה ב-  $O(1)$ . גישה זו מאפשרת ביצוע מהיר של מיזוגים חוזרים עד שמתקבל רצף תתי מילים סופי, תוך שמירה על כללי BPE שנלמדו. כך השגנו יעילות חישובית משמעותית בהשוואה לסריקה נאיבית של כל הכללים בכל שלב.

גודל מילון: 5000

דיווח ביצועים על סט המבחן: (יעילות ומהירות מדווחים לפי התוצאות בהרצת הקובץ test\_tokenizer)

- F1: Training complete. Best F1: 0.4672

- יעילות: Tokens per character: 0.3167

- מהירות inference: Total encoding time for test set: 25.8181 seconds

## tokenizer2 שאומן על domain 2:

הטמענו את כל השינויים שצוינו מעלה עבור טוקניזר 1, למעט הנרמול של lower case ונרמול הסרת של חזרתיות של אותיות.

גודל מילון: 10000

דיווח ביצועים על סט המבחן: (יעילות ומהירות מדווחים לפי התוצאות בהרצת הקובץ test\_tokenizer)

- F1: Training complete. Best F1: 0.9625

- יעילות: Tokens per character: 0.2590

- מהירות inference: Total encoding time for test set: 7.8321 seconds

## tokenizer3 עבור דאטה מוסתר:

הטמענו את כל השינויים שמזכרים בטוקניזר 1, למעט נרמול של lower case והסרה של סימני פיסוק עוקבים.

גודל מילון: 10000

בחרנו לאמן את הטוקניזר עם שימוש בדאטה משני domains: השתמשנו בכל המשפטים ב domain 2, וביצענו undersampling על domain 1 כך שדגמנו אקראית מספר משפטים השווה למספר משפטים שיש ב domain 2.

בצורה זו איזנו בין כמות המשפטים שמגיעים משני הדומיינים, ויצרנו מהם סט אחד עליו אומן הטוקניזר.

הערכת ביצועים – מכיוון שהטוקניזר השלישי מאומן על שני סוגי דאטה שונים (דאטה "מלוכלך" מרשתות חברתיות, ודאטה פורמלי יותר) אנחנו מעריכים שבהינתן דאטה חדש מודל ה NER נקבל ציון מדד F1 של עד כ-80% דיוק, ויעילות באיזור ה-0.3.

### דיווח

#### Bigrams

(הערה – אלו ה

bi grams

לאחר סינון של

determiners

ותווים שהם לא

(ascii

```
--- Bi-gram Frequency Report ---
5 Most Common Bi-grams:
('W>going', 'W>to'): 29272 occurrences
('W>to', 'W>be'): 23708 occurrences
('W>to', 'W>go'): 23539 occurrences
('W>I', 'W>have'): 22927 occurrences
('W>have', 'W>to'): 21675 occurrences

5 Least Common Bi-grams:
('W>Queen', 'W>will'): 1 occurrences
('W>ta', 'W>so'): 1 occurrences
('officialSusanB', 'W>ta'): 1 occurrences
('W>WS_FTP', 'W>Server'): 1 occurrences
('W>running', 'W>WS_FTP'): 1 occurrences
```

Domain 1

```
--- Bi-gram Frequency Report ---
5 Most Common Bi-grams:
('W>to', 'W>be'): 5777 occurrences
('W>Donald', 'W>Trump'): 5171 occurrences
('W>New', 'W>York'): 2547 occurrences
('W>want', 'W>to'): 2111 occurrences
('W>How', 'W>To'): 2009 occurrences

5 Least Common Bi-grams:
('W>Reflections', 'W>During'): 1 occurrences
('W>Giving', 'W>Culture'): 1 occurrences
('W>Wear', 'W>them'): 1 occurrences
('W>Woman', 'W>underwear'): 1 occurrences
('W>your', 'W>Wonder'): 1 occurrences
```

Domain 2